Digitaler Anhang A

Einzelbegründungen der Entscheidungsmatrix

zur Bachelorarbeit „LLM-gestützte Rekonstruktion von Softwareanforderungen aus der Entwicklungshistorie eines Open-Source-Projekts“
Omar Assad Salem, Hochschule RheinMain, 2026

Verweise auf Abschnitte, Tabellen und Abbildungen ohne den Präfix A beziehen sich auf die Arbeit. Dieser Anhang war in der Fassung vor der Kürzung Anhang A der Arbeit; sein Inhalt ist unverändert. Ergänzt sind am Ende die beiden Tabellen zum Quality-User-Story-Rahmenwerk aus dem früheren Abschnitt 2.2.3, auf die die Begründungen verweisen.

Anhang A

Einzelbegründungen der Entscheidungsmatrix

Dieser Anhang gibt die Einzelbegründungen zu den Noten der Entscheidungsmatrix aus Tabelle 4.4 in gekürzter Form wieder. Die vollständigen Begründungen einschließlich ihrer Änderungshistorie sind in der Arbeitsunterlage `docs/formatauswahl.md`, Abschnitt 10, des mit der Arbeit abgegebenen Repositorys dokumentiert; die Noten beider Fassungen stimmen überein. Die Leitfragen der Kriterien sind in Tabelle 4.1 aufgeführt.

Zu jeder Zelle werden drei Angaben gemacht. Die Belegstelle bezeichnet den Quelleninhalt, auf den sich die Note stützt. Begründung und Gegenargument sind eigene Einschätzungen; das Gegenargument nennt den stärksten Einwand gegen die vergebene Note und die Note, zu der er führen würde. Stützt sich ein Einwand auf Restprobleme, die eine Quelle aus einer Erprobung berichtet, lässt er die Note nach der in Abschnitt 4.1.1 dargestellten Auslegung der Stufe 2 unberührt; er wird dennoch aufgeführt. Der Wert *nicht anwendbar* ist keine schlechte Note, sondern zeigt an, dass eine Ebene die betreffende Eigenschaft ihrem Zweck nach nicht regelt. Die Noten für K6 und K9 beruhen auf der in Abschnitt 4.1.2 beschriebenen Messung, alle übrigen auf der Literatur. Die Noten wurden nach Prüfung an den Quellen von Hand vergeben. Zur Absicherung wurden Belegstellen, Notenvorschläge und Gegenargumente eines Sprachmodells hinzugezogen.

A.1 K1 Eindeutigkeit

(a) User Story, Note 1. *Beleg:* [2, Abschn. 2, 2.3 und 3.1.6]. *Begründung:* Die Schablone trennt Rolle, Means und Ends und legt für das Means drei grammatische

Bestandteile fest, sodass zumindest ein Teil des Satzes einer festen Lesart zugeordnet ist. Der übrige Text bleibt frei formulierbar, und Eindeutigkeit wird als gesondertes Qualitätskriterium geführt. *Gegenargument (spräche für Note 0):* Die Schablone ordnet den Satz, benennt aber keine Formulierung, die sie ausschließt.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 2, 4.1, 5 und 6]. *Begründung:* EARS legt die Bestandteile eines Satzes und ihre Reihenfolge fest und bestimmt, unter welcher Bedingung die Systemreaktion gilt; damit ist die Lesart des ganzen Satzes geregelt und nicht nur die eines Satzglieds. Die Quelle führt Mehrdeutigkeit als ausdrücklich adressiertes Problem und zeigt an Beispielen, welche Formulierungen ersetzt werden. *Gegenargument (spräche für Note 1):* Nach Angabe der Autoren wurde Mehrdeutigkeit in ihrer Erprobung nur verringert, nicht beseitigt [4, Abschn. 6].

(c) Normative Modalität, Note 1. *Beleg:* [6, Abschn. 1–5]; [7, Abschn. 2]. *Begründung:* Für das Modalwort ist die Lesart durch ein geschlossenes Vokabular und die Regel der durchgängigen Großschreibung eindeutig festgelegt. Für den übrigen Satz trifft die Konvention keine Aussage. *Gegenargument (spräche für Note 2):* Innerhalb ihrer Reichweite ist die Regel vollständig und an keine Bedingung geknüpft. Als nicht anwendbar wird das Kriterium nicht geführt, weil die Ebene Lesarten regelt, wenn auch nur für ein einzelnes Wort.

(d) Qualitäts-, Sprach- und Attributregeln, Note 2. *Beleg:* [1, Abschn. 5.2.5 und 5.2.7]; [3, Abschn. Testing the Hypothesis]; [2, Tab. 1 und Abschn. 3.1.6]. *Begründung:* Abschnitt 5.2.7 des Standards führt in neun Aufzählungspunkten Wortklassen auf, die in Anforderungen zu vermeiden sind. Die Ebene schließt damit als einzige der vier Ebenen einzelne Formulierungen namentlich und in normativer Form aus. *Gegenargument (spräche für Note 1):* Die Regeln benennen Wortklassen, aber kein Verfahren, das Eindeutigkeit herstellt; sie machen Verstöße erkennbar, verhindern sie aber nicht.

A.2 K2 Formale Struktur

Für die Ebenen (c) und (d) wird das Kriterium als nicht anwendbar geführt und nicht mit 0 bewertet, weil beide ihrem Zweck nach keine Satzbestandteile regeln. Dieselbe Erwägung liegt der Nichtanwendbarkeit von K6 für diese Ebenen zugrunde. Dagegen spricht, dass ISO/IEC/IEEE 29148 eine Schlüsselwortkonvention mit einem Aufbausatz verbindet [1, Abschn. 5.2.4] und dass die Zuordnung dieses Aufbausatzes zu Ebene (b) eine eigene Setzung ist. Die Einstufung als nicht anwendbar ist insoweit auch eine Folge dieser Zuordnung.

(a) User Story, Note 1. *Beleg:* [2, Abschn. 2 mit Abb. 1, 2.1, 2.3, 3.2.2 und 4.7]. *Begründung:* Das Begriffsmodell benennt vier Bestandteile und legt für das Means drei grammatische Elemente fest, sodass ein Satz in der verbreiteten Schablone ohne Deutung zerlegbar ist. Die Schablone selbst gibt der Ansatz jedoch nicht vor; er verweist auf über achtzig syntaktische Varianten und bestimmt die maßgebliche Form je Datensatz nach ihrer Häufigkeit. *Gegenargument (spräche für Note 2):* Die Kriterien Well-formed, Atomic und Minimal (Tabelle A.2) legen fest, welche Bestandteile ein Satz enthalten muss und welche nicht; in der verbreiteten Form steht auch die Reihenfolge fest. *Hinweis zur Stufe 2:* Die geringe Genauigkeit der selbsttätigen Prüfung beim Kriterium Well-formed (Tabelle A.3) ist ein Erprobungsbefund und trägt die Note nicht. Diese stützt sich allein darauf, dass der Ansatz die Schablone offenlässt.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 4.1–4.7]; [3, Abschn. EARS Templates]. *Begründung:* EARS benennt vier Bestandteile und erklärt ihre Reihenfolge ausdrücklich für bedeutsam, weil sie der zeitlichen Logik folgt. Vier der fünf Muster geben zusätzlich eine eigene Satzform mit festem Schlüsselwort vor; das fünfte gilt ohne Bedingung und ohne Auslöser. *Gegenargument (spräche für Note 1):* Vorbedingung und Auslöser sind optional, und die Abgrenzung zwischen den Mustern Ubiquitous und Event-driven kann nach Angabe der Autoren der Folgearbeit schwierig sein [3, Abschn. Lessons Learned Applying EARS]. *Hinweis zur Stufe 2:* Der zweite Teil des Einwands ist ein Erprobungsbefund und trägt die Note nicht. Der erste Teil betrifft die Reichweite der Regel; optionale Satzteile heben die festgelegte Reihenfolge jedoch nicht auf, sie entfallen nur.

(c) Normative Modalität, nicht anwendbar. *Beleg:* [6, Abschn. 1–5] und [7, Abschn. 2] treffen keine Aussage zum Satzbau. *Begründung:* Die Ebene legt allein die Bedeutung von Schlüsselwörtern fest und regelt weder Satzbestandteile noch deren Reihenfolge. *Gegenargument (spräche für Note 0):* siehe die Vorbemerkung zu diesem Kriterium.

(d) Qualitäts-, Sprach- und Attributregeln, nicht anwendbar. *Beleg:* [1, Abschn. 5.2.7, 5.2.8.1 und 5.2.8.2]; [2, Tab. 1]; [3, Abschn. Testing the Hypothesis]. *Begründung:* Die Ebene beurteilt eine bereits formulierte Anforderung. Abschnitt 5.2.7 nennt zu vermeidende Wortklassen, Abschnitt 5.2.8 Attribute neben dem Satz; beides sind weder Satzbestandteile noch eine Reihenfolge. *Gegenargument (spräche für Note 0):* siehe die Vorbemerkung zu diesem Kriterium. Die Attribute sind zwar benannte Felder mit fester Bedeutung, stehen aber neben dem Satz und nicht in ihm; erheblich werden sie erst für K4.

A.3 K3 Verifizierbarkeit

(a) User Story, Note 1. *Beleg:* [2, Abschn. 1, 3.1.3 und Tab. 1]. *Begründung:* Der Ansatz zählt Akzeptanzkriterien ausdrücklich zu den drei Bestandteilen einer User Story. Im Anforderungstext selbst dürfen sie nach dem Kriterium Minimal jedoch nicht stehen, und keines der dreizehn Qualitätskriterien prüft die Nachweisbarkeit. *Gegenargument (spräche für Note 0):* Bewertet wird der Anforderungstext, und für ihn erzwingt der Ansatz keine überprüfbare Angabe; die Akzeptanzkriterien liegen außerhalb und bleiben ungeprüft.

(b) EARS, Note 1. *Beleg:* [4, Abschn. 2 und 4.1]; [3, Abschn. Residual Problems]. *Begründung:* Die Syntax erzwingt eine Systemreaktion und damit ein beobachtbares Verhalten, und Untestbarkeit gehört zu den acht Problemen, die EARS ausdrücklich adressiert. Eine Regel, die eine messbare Größe oder ein Abnahmekriterium verlangt, enthält der Ansatz jedoch nicht. *Gegenargument (spräche für Note 2):* Die Beseitigung der Untestbarkeit ist ein erklärtes Ziel des Ansatzes, und Vorbedingung, Auslöser und Systemreaktion benennen genau die Angaben, gegen die geprüft wird. *Hinweis zur Stufe 2:* Die in der Folgearbeit berichtete verbleibende Untestbarkeit durch nicht quantifizierbare Wörter ist ein Erprobungsbefund und trägt die Note nicht. Diese stützt sich allein darauf, dass eine Regel zur Quantifizierung fehlt.

(c) Normative Modalität, nicht anwendbar. *Beleg:* [6] und [7] treffen keine Aussage darüber, woran die Erfüllung einer Anforderung überprüft wird. *Begründung:* Die Konvention legt allein die Verbindlichkeitsstufe fest und regelt ihrem Zweck nach nicht die Nachweisbarkeit. *Gegenargument (spräche für Note 0):* Die Verbindlichkeitsstufe entscheidet mit darüber, ob etwas überhaupt nachzuweisen ist; die Konvention berührt die Nachweisbarkeit damit mittelbar.

(d) Qualitäts-, Sprach- und Attributregeln, Note 2. *Beleg:* [1, Abschn. 5.2.5 und 5.2.7]. *Begründung:* Der Standard führt die Nachweisbarkeit als eigenes Merkmal jeder einzelnen Anforderung und begründet die Liste zu vermeidender Ausdrücke ausdrücklich damit, dass diese die Überprüfung erschweren oder unmöglich machen. Damit liegt eine ausdrückliche und weitgehend operationalisierte Regel vor. *Gegenargument (spräche für Note 1):* Messbarkeit wird nur als förderlich für die Nachweisbarkeit bezeichnet, nicht verlangt, und die Regeln nennen, was zu vermeiden ist, nicht, welche Angabe eine Anforderung enthalten muss.

A.4 K4 Maschinelle Verarbeitbarkeit

Das Kriterium ist eine eigene Setzung, gestützt auf die Klauselstruktur von EARS (Tabelle 4.1). Ein aus einem der bewerteten Ansätze abgeleitetes Kriterium begünstigt diesen Ansatz; die Note der Ebene (b) ist daher nur begrenzt aussagekräftig. Dieser Vorbehalt wurde vor der Notenvergabe festgehalten und wird in Kapitel 7 als Bedrohung der Konstruktvalidität aufgegriffen.

(a) User Story, Note 2. *Beleg:* [2, Abschn. 2 mit Abb. 1, 2.3, 3.2 und 4.3]. *Begründung:* Der Ansatz definiert eine User Story formal als Viertupel aus Rolle, Means, Ends und Format und das Means seinerseits als Fünftupel. Damit besteht eine ausdrückliche Zuordnung von Satzteil zu Feld bis hinunter zur grammatischen Ebene des Means. *Gegenargument (spräche für Note 1):* Das Format ist selbst eines der Felder und wird nicht festgelegt. Ohne Kenntnis der verwendeten Schablone bestimmt der Ansatz allein nicht, wo Rolle, Means und Ends im Text beginnen.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 4.1–4.6]; [5, Tab. I]. *Begründung:* Die generische Syntax besteht aus benannten Platzhaltern, die im Satz durch feste Schlüsselwörter voneinander abgegrenzt sind. Eine spätere Arbeit derselben Autoren behandelt diese Bestandteile bereits als einzeln adressierbare Teile. *Gegenargument (spräche für Note 1):* Die Quellen benennen Satzteile, definieren aber weder ein Datenmodell noch Feldnamen; die Abbildung auf Datenfelder ist eine Ergänzung der vorliegenden Arbeit.

(c) Normative Modalität, Note 1. *Beleg:* [6, Abschn. 1–5]; [7, Abschn. 2]. *Begründung:* Das Schlüsselwort lässt sich verlustfrei auf ein einzelnes Feld mit fünf zulässigen Stufen abbilden, und die Regel der Großschreibung grenzt es im Text eindeutig ab. Abgedeckt ist damit genau ein Feld, nicht der Satz. *Gegenargument (spräche für nicht anwendbar):* Die Ebene bringt keinen Satz hervor, während die Leitfrage von einem nach dem Ansatz formulierten Satz spricht. Als nicht anwendbar wird das Kriterium dennoch nicht geführt, weil die Ebene etwas Abbildbares regelt, wenn auch eng.

(d) Qualitäts-, Sprach- und Attributregeln, Note 1. *Beleg:* [1, Abschn. 5.2.8.1 und 5.2.8.2]. *Begründung:* Der Standard benennt Attribute wie Kennung, Versionsnummer, Eigner, Priorität, Risiko, Begründung und Schwierigkeitsgrad als Felder mit fester Bedeutung, die eine Anforderung begleiten. Sie stehen jedoch neben dem Satz, und eine Zuordnung von Satzteil zu Feld gibt der Ansatz nicht vor. *Gegenargument (spräche für Note 2):* Für die Ausgabe der Pipeline sind gerade diese Attribute die Felder neben dem Anforderungstext; ihre Benennung ist im Standard festgelegt und vollständig übernehmbar.

A.5 K5 Eignung für Modellausgaben

Die Noten dieses Kriteriums stützen sich nicht auf Untersuchungen zum Verhalten von Sprachmodellen, sondern auf drei strukturelle Ersatzgrößen: die Zahl der Pflichtbestandteile, die Zahl zulässiger Schreibvarianten und das Vorhandensein eines Musters für den Fall, dass keine Anforderung vorliegt. Sie sind vorläufig und werden nach der Entwicklung der Prompts überprüft.

(a) User Story, Note 1. *Beleg:* [2, Tab. 1, Abschn. 2 und 3.2.2]. *Begründung:* Zwei Pflichtbestandteile und die Begrenzung durch das Kriterium Minimal sind ein wirksamer Mechanismus zur Steuerung der Ausgabe. Der Ansatz legt jedoch keine Schablone fest, lässt über achtzig Varianten zu und kennt kein Muster für den Fall, dass keine Anforderung vorliegt. *Gegenargument (spräche für Note 0):* Die Ebene ist nur in vier von zwölf gemessenen Fällen gedeckt, ausschließlich wegen der fehlenden Rolle (Tabelle 4.3). Ein Format, das einen unbelegten Bestandteil verlangt, drängt ein Modell zum Erfinden.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 4.1–4.6]; [3, Abschn. Method]. *Begründung:* Zwei Pflichtbestandteile und ein geschlossener Satz von fünf Mustern mit festgelegten Schlüsselwörtern halten die Zahl zulässiger Schreibvarianten sehr klein. Für den Fall, dass keine Anforderung vorliegt, beschreibt die Folgearbeit ein ausdrückliches Verfahren: Jede Aussage wird vor der Umformulierung als Anforderung, Überschrift, Information oder für das betrachtete System nicht anwendbar eingestuft. *Gegenargument (spräche für Note 1):* Diese Einstufung gehört zum Verfahren der Folgearbeit und nicht zur Syntax; EARS als Format kennt kein Muster für eine Aussage, die keine Anforderung ist.

(c) Normative Modalität, Note 1. *Beleg:* [6, Abschn. 1–6]; [7, Abschn. 2]. *Begründung:* Ein geschlossenes Vokabular aus fünf Stufen mit eindeutiger Schreibweise ist für ein Sprachmodell leicht einzuhalten. Die in Abschnitt 6 von RFC 2119 geforderte sparsame Verwendung verlangt jedoch eine Abwägung, die ein Modell aus den Quelldaten nicht treffen kann. *Gegenargument (spräche für Note 0):* Eine Verbindlichkeitsstufe ist in keinem der zwölf gemessenen Fälle belegt (Tabelle 4.3); jede rekonstruierte Anforderung erforderte damit eine erfundene Stufe.

(d) Qualitäts-, Sprach- und Attributregeln, nicht anwendbar. *Beleg:* [1, Abschn. 5.2.5–5.2.8]; [2, Tab. 1]; [3, Abschn. Testing the Hypothesis]. *Begründung:* Die Ebene gibt weder ein Ausgabemuster noch Pflichtbestandteile vor, während alle drei Ersatzgrößen ein solches Muster voraussetzen. *Gegenargument (spräche für eine Note):* Die Liste zu vermeidender Ausdrücke aus Abschnitt 5.2.7 lässt sich

unmittelbar in eine Anweisung an ein Sprachmodell übersetzen. Für dessen Steuerung ist die Ebene damit einschlägig, nur nicht über ein Satzmuster.

A.6 K6 Eignung für die drei Anforderungsarten

Die Noten dieses Kriteriums stammen nicht aus der Literatur, sondern aus der in Abschnitt 4.1.2 beschriebenen Messung. Rahmen und Referenzinhalte wurden von Hand festgelegt, die sechs Sätze der Tabelle A.1 von Hand formuliert und eingestuft. Zur Absicherung hat ein Sprachmodell Vorschläge für Rahmen und Referenzinhalte geliefert und die Einstufungen anschließend gegengeprüft; eine Note hat es nicht vorgeschlagen. Die vollständige Dokumentation der Messung steht in `docs/formatprobe_protokoll.md`.

Für die Ebenen (c) und (d) wird das Kriterium als nicht anwendbar geführt, weil ein Formulierungsversuch dort den Satzbau einer anderen Ebene übernehmen müsste. Dagegen spricht, dass die beiden gemessenen Kriterien damit nur dort greifen, wo eine Ebene ein Satzmuster vorgibt; Ebene (d) hat deshalb weder bei K6 noch bei K9 eine gemessene Note. Beide bewerteten Ebenen beziehen zudem je einen Pflichtbestandteil aus dem einheitlichen Rahmen der Probe, Ebene (a) die Rolle und Ebene (b) den Systemnamen; das Kriterium unterscheidet die beiden Ebenen daher nicht.

Tabelle A.1: Formulierungsversuche der Probe für das Kriterium K6

Art	Ebene	Anforderungssatz
funktional	(a) User Story	As a developer, I want inputs to be checked for validity before they are processed.
funktional	(b) EARS	The library shall check inputs for validity before processing them.
leistungs-bezogen	(a) User Story	As a developer, I want 95 % of transactions to be processed in less than 1 s.
leistungs-bezogen	(b) EARS	The library shall process 95 % of transactions in less than 1 s.
sicherheits-bezogen	(a) User Story	As a developer, I want the integrity of data in critical variables to be checked.
sicherheits-bezogen	(b) EARS	The library shall check the integrity of data in critical variables.

(a) User Story, Note 2. *Beleg:* drei von drei Versuchen gelungen (Tabelle A.1). *Begründung:* In allen drei Versuchen sind Rolle und Means besetzt, ohne dass

eine Angabe hinzukommt, die Rahmen oder Referenzinhalt nicht hergeben. Eine von der Anforderungsart abhängige Schwäche zeigt sich bei keiner der drei Arten. *Gegenargument (spräche für Note 0):* Die Rolle stammt in allen drei Sätzen aus dem Rahmen und nicht aus dem Referenzinhalt; würde sie nicht als belegt gelten, gelänge kein einziger Versuch.

(b) EARS, Note 2. *Beleg:* drei von drei Versuchen gelungen (Tabelle A.1). *Begründung:* In allen drei Versuchen sind Systemname und Systemreaktion besetzt, wobei die Systemreaktion jeweils dem Referenzinhalt selbst entstammt. Auch hier zeigt sich bei keiner der drei Anforderungsarten eine Schwäche. *Gegenargument (spräche für Note 0):* Der Systemname stammt ebenso aus dem Rahmen wie bei Ebene (a) die Rolle; würde auch er nicht als belegt gelten, gelänge gleichfalls kein Versuch.

(c) Normative Modalität, nicht anwendbar. *Beleg:* [6, Abschn. 1–5] und [7, Abschn. 2] treffen keine Aussage zum Satzbau. *Begründung:* Die Ebene legt allein die Bedeutung von Schlüsselwörtern fest; ein Formulierungsversuch müsste den Satzbau einer anderen Ebene übernehmen und bewertete damit diese. *Gegenargument (spräche für eine Note):* siehe die Vorbemerkung zu diesem Kriterium.

(d) Qualitäts-, Sprach- und Attributregeln, nicht anwendbar. *Beleg:* [1, Abschn. 5.2.5–5.2.7]. *Begründung:* Die Ebene nennt Merkmale und sprachliche Kriterien, aber keine Satzbestandteile, und beurteilt eine bereits formulierte Anforderung. *Gegenargument (spräche für eine Note):* Ob die Qualitätsregeln bei den drei Anforderungsarten unterschiedlich greifen, bleibt damit ungemessen; dieser Gesichtspunkt geht nur mittelbar über K3 ein.

A.7 K7 Verständlichkeit

Dieses Kriterium wird nur ersatzweise bewertet. Belastbar wird es erst durch eine Bewertung durch das Qrisp-Team, die für die Zeit nach der Abgabe vorgesehen ist; die Selbstbewertung in Abschnitt 6.4 ersetzt sie nicht. Sein zweiter Prüfpunkt, der Abstand zur Ausdrucksweise in den Pull Requests, ist eine eigene Setzung ohne Beleg in einer Quelle; wo er eine Note trägt, ist das bei der betreffenden Zelle ausgewiesen.

(a) User Story, Note 1. *Beleg:* [2, Abschn. 1 und 2.2]. *Begründung:* Drei Signalphrasen in Alltagsenglisch ohne Fachvokabular verlangen einer lesenden Person kaum Vorwissen ab. Die Schablone setzt jedoch eine Rolle aus der Anwendungsdomäne voraus, während die Pull Requests des Projekts sich an andere Entwickelnde richten und keinen Nutznießer benennen. *Gegenargument*

(spräche für Note 2): Nach dem ersten Prüfpunkt, der Zahl der zu lernenden Schlüsselwörter und Regeln, schneidet die Ebene von allen vieren am besten ab. *Ausweis der eigenen Setzung:* Der Abzug beruht allein auf dem zweiten Prüfpunkt und ist damit gesetzt, nicht belegt.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 2 und 4.1–4.6]. *Begründung:* Der Ansatz lehnt formale und grafische Notationen ausdrücklich wegen Übersetzungsfehlern, Sprachbarriere und Schulungsaufwand ab und ist darauf angelegt, ohne Schulung lesbar zu bleiben. Seine Satzform nennt das System als Handelnden, so wie die Pull Requests über die Bibliothek sprechen. *Gegenargument (spräche für Note 1):* Zu lernen sind fünf Muster mit vier Schlüsselwörtern, das Wort *shall* und die verbindliche Klauselreihenfolge; *shall* ist in der Sprache der Pull Requests unüblich. *Hinweis zur Stufe 2:* Die in der Folgearbeit berichtete Schwierigkeit, die Muster Ubiquitous und Event-driven auseinander zu halten, ist ein Erprobungsbefund und trägt die Note nicht [3, Abschn. Lessons Learned Applying EARS].

(c) Normative Modalität, Note 1. *Beleg:* [6, Abschn. 1–5]; [7, Abschn. 1 und 2]. *Begründung:* Die fünf Verbindlichkeitsstufen werden mit elf geläufigen englischen Wörtern ausgedrückt, sodass dem Wortschatz nach nichts Fremdes zu lernen ist. Genau darin liegt die Falle: Wer die Konvention nicht kennt, liest *SHOULD* als unverbindliche Empfehlung, und RFC 8174 wurde eigens erlassen, weil die Unterscheidung nach Groß- und Kleinschreibung nicht eindeutig war. *Gegenargument (spräche für Note 2):* Fünf Bedeutungen sind ein überschaubarer Lernaufwand, und die durchgängige Großschreibung macht sichtbar, dass überhaupt eine Konvention gilt.

(d) Qualitäts-, Sprach- und Attributregeln, Note 2. *Beleg:* [1, Abschn. 5.2.6 und 5.2.7]. *Begründung:* Der Standard führt die Verständlichkeit als eigenes Merkmal und untersagt unbestimmte und mehrdeutige Ausdrücke. Die Regeln richten sich an die verfassende Person und nicht an die lesende; diese muss nichts lernen. *Gegenargument (spräche für Note 1):* Das Merkmal gilt nach Abschnitt 5.2.6 für die Menge der Anforderungen, während das Kriterium nach dem Lesen eines einzelnen Satzes fragt; überdies sagt der Standard, was zu vermeiden ist, und nicht, wie ein verständlicher Satz aussieht.

A.8 K8 Automatische Validierbarkeit

(a) User Story, Note 1. *Beleg:* [2, Abschn. 4, 4.2 und 4.7]. *Begründung:* Mit AQUSA liegt ein veröffentlichtes Werkzeug vor, das die Formatkonformität je Kriterium

prüft; ein Mechanismus ist damit zweifelsfrei vorhanden. Er ist jedoch an eine Bedingung geknüpft, weil der Ansatz keine feste Schablone vorgibt und deshalb gegen eine je Datensatz aus der Häufigkeit bestimmte Form geprüft wird. *Gegenargument (spräche für Note 2):* Dies ist die einzige der vier Ebenen mit einem tatsächlich gebauten und veröffentlichten Prüfwerkzeug. *Hinweis zur Stufe 2:* Die gemessene Leistungsfähigkeit dieses Werkzeugs (Tabelle A.3) ist ein Erprobungsbefund und trägt die Note nicht.

(b) EARS, Note 2. *Beleg:* [4, Abschn. 4.1–4.6]. *Begründung:* Die Schlüsselwörter der vier bedingten Muster und das Modalwort *shall* bilden ein geschlossenes Vokabular, das ein Programm unmittelbar suchen kann, und das fünfte Muster ist am Fehlen eines Schlüsselworts erkennbar. Die festgelegte Klauselreihenfolge macht zusätzlich prüfbar, ob ein Satz dem Muster folgt und nicht nur dessen Wörter enthält. *Gegenargument (spräche für Note 1):* In den ausgewerteten Quellen ist kein Prüfwerkzeug für den Ansatz beschrieben; die maschinelle Prüfbarkeit ist aus der Syntax abgeleitet, aber nicht gezeigt.

(c) Normative Modalität, Note 2. *Beleg:* [6, Abschn. 1–6]; [7, Abschn. 2]. *Begründung:* Das Vokabular ist geschlossen und durch die Regel der durchgängigen Großschreibung im Fließtext eindeutig abgegrenzt, sodass eine einfache Suche genügt, um festzustellen, ob und welche Stufe verwendet wurde. *Gegenargument (spräche für Note 1):* Ein Programm findet das Schlüsselwort, kann aber die in Abschnitt 6 geforderte sparsame Verwendung nicht prüfen; diese Regel für inhaltlich zentral zu halten, ist allerdings eine eigene Einordnung, da die Quelle den Abschnitt als Hinweis zur Anwendung führt.

(d) Qualitäts-, Sprach- und Attributregeln, Note 1. *Beleg:* [1, Abschn. 5.2.5 und 5.2.7]. *Begründung:* Die neun Klassen unbestimmter Ausdrücke lassen sich in Suchregeln überführen, ein Mechanismus ist also vorhanden. Er reicht aber nur so weit: Die Wortbeispiele je Klasse sind nicht abschließend, und Merkmale wie notwendig, umsetzbar oder korrekt sind maschinell nicht prüfbar. *Gegenargument (spräche für Note 2):* Für den Zweck des Kriteriums genügt, dass die sprachlichen Regeln prüfbar sind; die übrigen Merkmale betreffen den Inhalt und nicht die Formkonformität.

A.9 K9 Deckung durch die Quelldaten

Die Noten dieses Kriteriums stammen aus der in Abschnitt 4.1.2 beschriebenen Messung an zwölf Pull Requests; Tabelle 4.3 führt die gemessenen Werte auf. Als gedeckt gilt ein Fall, wenn sich jeder Pflichtbestandteil der Ebene aus Titel, Beschreibung, Kommentaren oder Änderungsdiff belegen lässt, bei Ebene (a) also Rolle und

Means, bei Ebene (b) Systemname und Systemreaktion und bei Ebene (c) die Verbindlichkeitsstufe. Bei zwölf Fällen sind die Schwellen von zehn gedeckten Fällen für die Note 2 und von fünf für die Note 1 wirksam.

Die Messung wurde von Hand durchgeführt; zur Absicherung hat ein Sprachmodell alle zwölf Fälle unabhängig gegengeprüft. Die fünf Einstufungen, die daraufhin nach Prüfung an der Quelle geändert wurden, betrafen sämtlich Ebene (c). Die vollständige Dokumentation steht in `docs/formatprobe_protokoll.md`.

(a) User Story, Note 0. *Beleg:* vier von zwölf Fällen gedeckt (Tabelle 4.3). *Begründung:* Alle acht nicht gedeckten Fälle scheitern allein am Bestandteil Rolle, während das Means in allen zwölf Fällen belegt ist. Zwei der vier gedeckten Fälle nennen eine Personengruppe nur pauschal; ohne sie wären zwei von zwölf Fällen gedeckt, und die Note bliebe bei 0. *Gegenargument (spräche für Note 1):* Zur nächsten Schwelle fehlt ein einziger Fall.

(b) EARS, Note 1. *Beleg:* neun von zwölf Fällen gedeckt (Tabelle 4.3). *Begründung:* In den drei nicht gedeckten Fällen fehlt entweder ein eindeutig benanntes Bauteil oder eine konkrete Handlung. In zwei von ihnen lag der Änderungstext nur teilweise vor, und nicht sichtbare Einzelheiten wurden nicht ergänzt. *Gegenargument (spräche für Note 2):* Zur nächsten Schwelle fehlt ein einziger Fall.

(c) Normative Modalität, Note 0. *Beleg:* kein Fall von zwölf gedeckt (Tabelle 4.3). *Begründung:* Modalaussagen kommen in fünf Fällen vor, betreffen dort aber das Vorgehen im Pull Request, eine andere Anforderung oder ein benachbartes Bauteil. Als Beleg gilt eine Stufe nur, wenn sich die Aussage auf die rekonstruierte Anforderung selbst bezieht. *Gegenargument (spräche für Note 1):* Ohne diese Einschränkung wären fünf von zwölf Fällen gedeckt und die Note läge bei 1, sodass auch die oben genannte Ausschlussregel nicht mehr griffe; die fünf Einstufungen gehen sämtlich auf die Gegenprüfung durch ein Sprachmodell zurück.

(d) Qualitäts-, Sprach- und Attributregeln, nicht anwendbar. *Beleg:* [1, Abschn. 5.2.5–5.2.7]. *Begründung:* Die Ebene schreibt keine Satzbestandteile vor, sondern Qualitäts- und Sprachregeln; ein Deckungsanteil ist für sie nicht definiert. *Gegenargument (spräche für eine Note):* Der Standard sieht Attribute neben dem Anforderungssatz vor [1, Abschn. 5.2.8.1], und das gewählte Zielformat verlangt drei von ihnen; ob die Quelldaten diese hergeben, wurde nicht gemessen.

A.10 K10 Kombinierbarkeit

(a) User Story, Note 1. *Beleg:* [1, Abschn. 5.2.4 NOTE 2]; [2, Abschn. 1 und Tab. 1]. *Begründung:* Der Standard lässt User Stories ausdrücklich zu, sodass die Verbindung mit Ebene (d) belegt möglich ist. Die Schablone besetzt jedoch den ganzen Satz und lässt nach dem Kriterium Minimal keinen Platz für die Klauseln der Ebene (b) oder ein Modalwort der Ebene (c). *Gegenargument (spräche für Note 2):* Die Ebene ist die einzige, deren Verträglichkeit eine Norm ausdrücklich bestätigt, und die Unvereinbarkeit mit Ebene (b) betrifft nur den einzelnen Satz.

(b) EARS, Note 1. *Beleg:* [4, Abschn. 4.1]; [1, Abschn. 5.2.4]; [6, Abschn. 1–5]. *Begründung:* Mit Ebene (d) ist der Ansatz verträglich, weil er dasselbe Modalwort verwendet, das der Standard für verbindliche Anforderungen vorsieht. Zur Ebene (c) in ihrer Ausprägung nach RFC 2119 besteht dagegen ein Widerspruch, weil der Ansatz nur *shall* kennt und keine Abstufung. *Gegenargument (spräche für Note 2):* Der Widerspruch besteht nicht zur Ebene (c) als solcher, sondern nur zu einer ihrer beiden Ausprägungen; mit den Schlüsselwörtern des Standards ist der Ansatz widerspruchsfrei.

(c) Normative Modalität, Note 1. *Beleg:* [6, Abschn. 1–5]; [1, Abschn. 5.2.4]. *Begründung:* Der Konflikt liegt innerhalb der Ebene selbst, denn der Standard rät von *must* ab, während RFC 2119 *MUST* und *SHALL* gleichsetzt und fünf Stufen statt einer kennt. Er ist auflösbar, sobald eine der beiden Konventionen gewählt wird. *Gegenargument (spräche für Note 2):* In der Ausprägung nach dem Standard ist die Ebene mit den Ebenen (b) und (d) widerspruchsfrei. *Hinweis:* Diese Wahl ist inzwischen zugunsten der Schlüsselwörter des Standards gefallen (Abschnitt 4.1.4); die Note bleibt dennoch bei 1, weil sie die Ebene als Ganzes bewertet und die Bewertung auf dem Stand bleiben soll, auf dem sie in die Entscheidung eingegangen ist.

(d) Qualitäts-, Sprach- und Attributregeln, Note 2. *Beleg:* [1, Abschn. 5.2.4 NOTE 2 und 5.2.5–5.2.7]. *Begründung:* Die Regeln beurteilen einen fertigen Satz und schreiben keine Satzform vor; sie kollidieren deshalb mit keiner Satzform. Der Standard nennt User Stories sogar ausdrücklich als zulässige alternative Formulierung. *Gegenargument (spräche für Note 1):* Vollständige Konformität mit dem Standard setzt voraus, dass die Abschnitte 5.2.4 bis 5.2.7 gemeinsam eingehalten werden [1, Abschn. 4.2], und für die Inhaltsvorgaben schließt er ein Anpassen bei vollständiger Konformität ausdrücklich aus [1, Anhang C.1]; eine Verbindung, die nur einen Teil dieser Vorgaben übernimmt, gibt den Anspruch auf Konformität auf.

A.11 Tabellen zum Quality-User-Story-Rahmenwerk

Tabelle A.2: Die dreizehn Kriterien des Quality-User-Story-Rahmenwerks nach [2, Tab. 1]

Kriterium	**Bedeutung**	**Bezug**
Syntaktisch		
Well-formed	enthält mindestens eine Rolle und ein Means	einzeln
Atomic	beschreibt genau ein Merkmal	einzeln
Minimal	enthält nichts außer Rolle, Means und Ends	einzeln
Semantisch		
Conceptually sound	das Means benennt ein Merkmal, das End eine Begründung	einzeln
Problem-oriented	benennt nur das Problem, nicht dessen Lösung	einzeln
Unambiguous	vermeidet Begriffe, die mehrere Deutungen zulassen	einzeln
Conflict-free	steht zu keiner anderen Story im Widerspruch	Menge
Pragmatisch		
Full sentence	ist ein wohlgeformter vollständiger Satz	einzeln
Estimatable	ist nicht so grob gefasst, dass Planung und Priorisierung erschwert werden	einzeln
Unique	kommt kein zweites Mal vor	Menge
Uniform	verwendet dieselbe Schablone wie die übrigen Stories	Menge
Independent	ist in sich abgeschlossen, ohne inhärente Abhängigkeiten	Menge
Complete	die Umsetzung der Menge ergibt eine funktionsvollständige Anwendung	Menge

Literaturverzeichnis

[1] ISO/IEC/IEEE. Systems and software engineering — life cycle processes — requirements engineering. ISO/IEC/IEEE 29148:2018(E), November 2018. Bezogen über IEEE Xplore, Abruf am 5. August 2026.

[2] Garm Lucassen, Fabiano Dalpiaz, Jan Martijn E. M. van der Werf, and Sjaak Brinkkemper. Improving agile requirements: The Quality User Story framework and tool. *Requirements Engineering*, 21(3):383–403, 2016. DOI: 10.1007/s00766-016-0250-x. Open Access, CC BY 4.0.

Tabelle A.3: Trefferquote und Genauigkeit der selbsttätigen Qualitätsprüfung von User Stories, ermittelt an 1023 Stories aus achtzehn Datensätzen [2, Tab. 4 und 5]

Kriterium	**Trefferquote**	**Genauigkeit**
Well-formed	95,7 %	42,3 %
Atomic	82,9 %	51,2 %
Minimal	95,5 %	69,5 %
Uniform	95,4 %	87,1 %
Unique	100 %	100 %
Gesamt (gewichtetes Mittel)	93,8 %	72,2 %

[3] Alistair Mavin and Philip Wilkinson. BIG EARS (the return of "easy approach to requirements syntax"). In *2010 18th IEEE International Requirements Engineering Conference*, pages 277–282. IEEE, 2010. DOI: 10.1109/RE.2010.39.

[4] Alistair Mavin, Philip Wilkinson, Adrian Harwood, and Mark Novak. Easy approach to requirements syntax (EARS). In *2009 17th IEEE International Requirements Engineering Conference*, pages 317–322. IEEE, 2009. DOI: 10.1109/RE.2009.9.

[5] Philip Wilkinson and Alistair Mavin. Deriving mitigation requirements with easy approach to requirements syntax. In *2018 1st International Workshop on Easy Approach to Requirements Syntax (EARS)*, pages 9–10. IEEE, 2018. DOI: 10.1109/EARS.2018.00008.

Online-Quellen

[6] Scott Bradner. Key words for use in RFCs to Indicate Requirement Levels. RFC 2119, BCP 14, IETF. `https://www.rfc-editor.org/rfc/rfc2119`, März 1997. DOI 10.17487/RFC2119. Aktualisiert durch RFC 8174. Abruf am 6. August 2026.

[7] Barry Leiba. Ambiguity of Uppercase vs Lowercase in RFC 2119 Key Words. RFC 8174, BCP 14, IETF. `https://www.rfc-editor.org/rfc/rfc8174`, Mai 2017. Aktualisiert RFC 2119. Abruf am 6. August 2026.