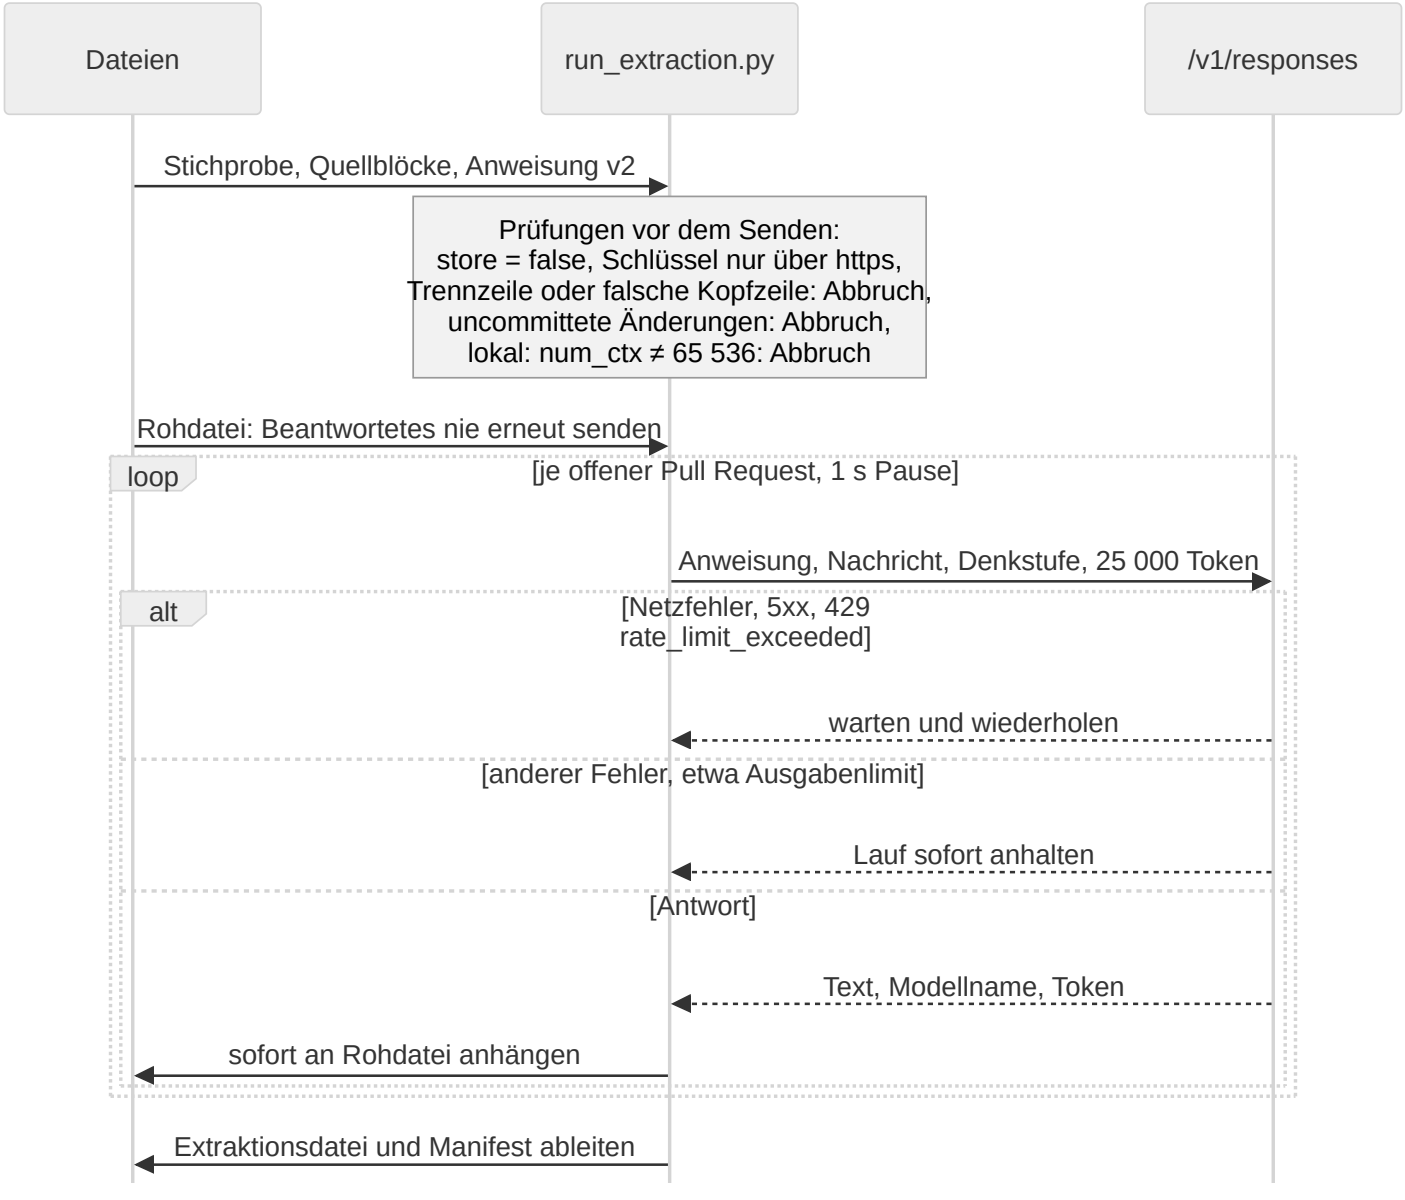
Dateien
run_extraction.py
/v1/responses
Stichprobe, Quellblöcke, Anweisung v2
Prüfungen vor dem Senden:
store = false, Schlüssel nur über https,
Trennzeile oder falsche Kopfzeile: Abbruch,
uncommittete Änderungen: Abbruch,
lokal: num_ctx ≠ 65 536: Abbruch
Rohdatei: Beantwortetes nie erneut senden
loop
[je offener Pull Request, 1 s Pause]
Anweisung, Nachricht, Denkstufe, 25 000 Token
alt
[Netzfehler, 5xx, 429
rate_limit_exceeded]
warten und wiederholen
[anderer Fehler, etwa Ausgabenlimit]
Lauf sofort anhalten
[Antwort]
Text, Modellname, Token
sofort an Rohdatei anhängen
Extraktionsdatei und Manifest ableiten